

论文题目

摘要

随着 xx 的发展,xx 问题是 xx 中的重要研究课题 (或 xx 现象日益严重)。本文针对 xx 中的问题,基于 xx 和 xx 思想,通过确定 xx、xx、xx 等指标,以 xx、xx 为目标建立了 xx 模型,并使用 xx 算法对模型进行求解。

针对问题一,

针对问题二,

针对问题三,

最后,我们对提出的模型进行全面的评价:本文的模型贴合实际,能合理解决提出的
问题,具有实用性强,算法效率高等特点,该模型在 xx,xx,xx 方面也能使用。

关键词: 关键词 1 关键词 2 关键词 3 关键词 4 关键词 5

一、问题重述

1.1 问题背景

1.2 问题提出

问题一：
问题二：
问题三：

二、问题分析

问题一：
问题二：
问题三：

三、模型假设与符号说明

3.1 模型基本假设

- (1)
- (2)
- (3)

3.2 符号说明

表1 符号说明

符号	含义	单位
----	----	----

四、数据预处理

4.1 指标选取

4.2 数据清洗

五、模型建立与求解

5.1 问题一模型建立与求解

5.1.1 问题一求解思路

问题1要求在第四次至第七次人口普查时间段内,基于人口普查数据中的基本指标,对我国不同省级区域的人口分布特征进行类别划分。

该问题的核心不是单纯比较各省人口数量大小,而是要综合考虑人口规模、年龄结构、性别结构、受教育水平、城乡分布以及人口变化趋势等因素,识别不同地区在人口分布上的结构性差异。因此,本问可构建“人口区域分布综合特征指标体系”,再利用综合评价与聚类分析相结合的方法完成区域分类。

本题附件中已经给出了1990年、2000年、2010年、2020年四次人口普查相关数据。由于人口区域分布具有明显的时间演化特征,因此仅使用某一年静态数据会导致分类结果片面。本文将区域人口特征拆分为两部分:一是2020年第七次人口普查反映的当前人口状态,二是1990—2020年或2000—2020年反映的人口变化趋势。

因此,分类模型的基本逻辑为:

先构建指标体系:

$$X_i = (x_{i1}, x_{i2}, \dots, x_{im})$$

其中, X_i 表示第 i 个省份的人口区域分布特征向量, x_{ij} 表示第 i 个省份在第 j 个指标上的取值。

再对各指标进行无量纲化处理,消除人口总量、比例指标、增长率指标之间的量纲差异。

最后基于标准化后的特征矩阵进行聚类分析,将人口分布特征相近的省份划分为同一类别。

5.1.2 问题一模型建立

1. 指标体系构建

根据题目要求和附件数据情况,本文从五个维度构建人口区域分布指标体系。

1.1 人口规模维度

人口规模是区域人口分布最基础的指标。人口总量越大,说明该地区人口承载能力、经济活动规模和社会服务需求越强。

选取指标:

$$P_i$$

其中, P_i 表示第 i 个省份2020年总人口。

由于不同省份人口规模差异很大,直接使用总人口会使广东、山东、河南等大人口省份对模型影响过强,因此对人口规模进行对数化处理:

$$L_i = \ln(P_i)$$

这样既保留人口规模差异,又降低极端大人口省份对聚类结果的支配作用。

1.2 人口增长维度

仅看2020年人口数量无法反映区域人口吸引力。部分地区当前人口规模不大,但增长速度较快;部分地区人口总量仍大,但增长缓慢甚至存在收缩趋势。

因此，构造 2000—2020 年年均人口增长率：

$$g_{i,2000-2020} = \left(\frac{P_{i,2020}}{P_{i,2000}} \right)^{\frac{1}{20}} - 1$$

同时构造 2010—2020 年年均人口增长率：

$$g_{i,2010-2020} = \left(\frac{P_{i,2020}}{P_{i,2010}} \right)^{\frac{1}{10}} - 1$$

其中， $P_{i,t}$ 表示第 i 个省份在年份 t 的总人口。

这两个指标可以共同反映长期人口吸引趋势和近十年人口变化状态。

1.3 年龄结构维度

人口年龄结构是区域人口分布差异的重要体现。少儿人口占比较高的地区通常具有较强的口增长潜力，而老年人口占比较高的地区则面临更大的养老压力和劳动力收缩风险。

选取指标：

$A_{i,0-14}$ ：0—14 岁人口占比

$A_{i,65+}$ ：65 岁及以上人口占比

进一步构造老龄化指数：

$$O_i = \frac{A_{i,65+}}{A_{i,0-14}}$$

当 O_i 越大，说明老年人口相对于少儿人口的比重越高，区域人口结构越趋于老龄化；当 O_i 越小，说明少儿人口占比相对较高，区域人口年龄结构更年轻。

1.4 性别结构维度

性别结构会影响婚育行为、家庭结构和未来人口再生产能力。本文选取性别比作为性别结构指标：

$$S_i = \frac{M_i}{F_i} \times 100$$

其中， M_i 表示男性人口， F_i 表示女性人口。

若 S_i 明显高于 100，说明男性人口占比较高；若 S_i 接近 100，说明性别结构较均衡。

1.5 人口素质维度

受教育水平反映区域人口质量，是评价人口高质量发展的重要指标。本文选取大专及以上学历人口占比和平均受教育年限作为人口素质指标：

$$E_{i,1} = \frac{C_i}{P_i} \times 100$$

$$E_{i,2} = \bar{Y}_i$$

其中， C_i 表示大专及以上学历人口， $\bar{Y}_i$ 表示平均受教育年限。

平均受教育年限可按不同教育层次人口加权估算：

$$\bar{Y}_i = \frac{16N_{i,college} + 12N_{i,high} + 9N_{i,junior} + 6N_{i,primary}}{N_{i,edu}}$$

其中, $N_{i,college}$ 、 $N_{i,high}$ 、 $N_{i,junior}$ 、 $N_{i,primary}$ 分别表示大专及以上学历、高中、初中、小学文化程度人口, $N_{i,edu}$ 表示参与教育水平统计的人口总量。

1.6 城乡分布与流动特征处理

题目明确提出应考虑城乡人口和流动人口。附件中 2000 年和 2010 年包含城镇化率, 但 2020 年表中未完整给出城乡人口指标, 且四个附件均未直接给出流动人口数据。

因此, 在当前附件数据条件下, 本文采用两种处理方式:

第一, 使用已有年份城镇化率反映区域城乡结构:

$$U_i = \frac{P_{i,urban}}{P_i} \times 100$$

第二, 使用人口增长率作为人口流动吸引能力的间接表征。若某地区长期人口增长率较高, 通常说明其具有较强的人口吸纳能力; 若人口增长率较低甚至为负, 则说明其人口流出或自然增长不足问题较明显。

因此, 将 $g_{i,2000-2020}$ 和 $g_{i,2010-2020}$ 纳入分类模型, 可以在一定程度上补偿流动人口指标缺失的问题。

2. 数据标准化处理

由于各指标量纲不同, 例如人口规模为“人”, 年龄结构为“百分比”, 增长率为“小数”, 若直接聚类会导致人口总量指标权重过大。因此需要对全部指标进行标准化处理。

对于正向指标, 例如人口增长率、受教育水平、城镇化率, 采用极差标准化:

$$z_{ij} = \frac{x_{ij} - \min(x_j)}{\max(x_j) - \min(x_j)}$$

对于逆向指标, 例如老龄化指数、65 岁及以上人口占比, 可采用:

$$z_{ij} = \frac{\max(x_j) - x_{ij}}{\max(x_j) - \min(x_j)}$$

如果采用 Z-score 标准化, 则统一处理为:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

其中, $\bar{x}_j$ 表示第 j 个指标的均值, s_j 表示第 j 个指标的标准差。

得到标准化矩阵:

$$Z = (z_{ij})_{n \times m}$$

其中, n 为省份数量, m 为指标数量。

3. 指标权重与综合特征提取

为了避免人为赋权过强, 本文可采用熵权法确定各指标权重。熵权法的基本思想是: 某指标在不同省份之间差异越大, 提供的信息量越多, 其权重越高。

首先计算第 j 个指标下第 i 个省份的比重:

$$p_{ij} = \frac{z_{ij}}{\sum_{i=1}^n z_{ij}}$$

第 j 个指标的信息熵为:

$$e_j = -k \sum_{i=1}^n p_{ij} \ln p_{ij}$$

其中:

$$k = \frac{1}{\ln n}$$

信息冗余度为：

$$d_j = 1 - e_j$$

最终得到指标权重：

$$w_j = \frac{d_j}{\sum_{j=1}^m d_j}$$

各省份的人口区域分布综合得分为：

$$F_i = \sum_{j=1}^m w_j z_{ij}$$

综合得分 F_i 可用于辅助解释区域人口发展水平，但本问的最终目标是“类别划分”，因此综合得分不直接作为唯一分类依据，而是与聚类分析结合使用。

4. 人口区域分布聚类模型

在完成指标标准化和特征构建后，采用 K-means 聚类方法划分人口区域类型。

K-means 模型的目标是使同一类别内部省份差异尽可能小，不同类别之间差异尽可能大。

设全部省份被划分为 K 类，类别中心为 $\mu_1, \mu_2, \dots, \mu_K$ ，则目标函数为：

$$\min J = \sum_{k=1}^K \sum_{i \in C_k} |Z_i - \mu_k|^2$$

其中， C_k 表示第 k 类省份集合， Z_i 表示第 i 个省份的标准化特征向量， μ_k 表示第 k 类的聚类中心。

聚类中心计算公式为：

$$\mu_k = \frac{1}{|C_k|} \sum_{i \in C_k} Z_i$$

样本到类别中心的距离为：

$$d_{ik} = \sqrt{\sum_{j=1}^m (z_{ij} - \mu_{kj})^2}$$

省份 i 被划分到距离最近的类别：

$$c_i = \arg \min_k d_{ik}$$

5. 聚类数确定

为避免主观指定类别数，本文使用轮廓系数判断合理聚类数。

对于第 i 个省份，设 a_i 为其与同类其他省份的平均距离， b_i 为其与最近其他类别中省份的平均距离，则轮廓系数为：

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

总体轮廓系数为：

$$S = \frac{1}{n} \sum_{i=1}^n s_i$$

当 S 越接近 1，说明聚类结果越合理；当 S 接近 0，说明类别边界不清晰；当 S 小于 0，说明存在较明显误分。

根据附件数据计算， $K=4$ 时分类解释性较强，既能区分京津沪等高度城镇化高教育地区，也能区分传统大人口地区、人口增长型地区以及海南这一特殊增长型地区。因此本文将全国省级区域划分为 4 类。

5.1.3 问题一模型求解与分析：人口区域分布类别划分

1. 指标权重结果分析

根据熵权法计算结果，各指标权重如下表所示。

排名	指标	熵权
1	人口增长率_2010_2020	0.3183
2	大专及以上学历占比_2020	0.2298
3	65 岁及以上占比_2020	0.0775
4	老龄化加深幅度_2000_2020	0.0629
5	0_14 岁占比_2020	0.0583
6	人口增长率_2000_2020	0.0569
7	城镇化率_2020	0.0509
8	老龄化指数_2020	0.0403
9	性别结构均衡度_2020	0.0373
10	人口规模_2020_对数	0.0313
11	平均受教育年限_2020	0.0209
12	大专及以上学历占比提升_2000_2020	0.0156

从权重结果看，2010—2020 年人口增长率权重最高，为 0.3183，说明近十年人口变化趋势对区域人口分布类别划分影响最大。这符合题目要求，因为题目关注的是 2020 年以来我国人口数量、结构、分布和居住等方面的变化，并要求基于第四次至第七次人口普查数据划分人口区域分布类别。

其次，大专及以上学历人口占比权重为 0.2298，说明人口受教育水平是区分不同区域人口发展状态的重要因素。北京、天津、上海等地区之所以被划入高城镇化高素质核心集聚型，与其较高的受教育水平密切相关。

相比之下，人口规模本身权重较低，仅为 0.0313，说明本模型并不是简单按照人口总量大小分类，而是更加重视人口增长能力、人口素质和人口结构特征。

2. 聚类数选择结果

不同聚类数下的轮廓系数如下。

聚类数 K	轮廓系数
2	0.3457
3	0.3221
4	0.2796
5	0.3322
6	0.3313
7	0.3377

从数值上看， $K=2$ 时轮廓系数最高，为 0.3457。但若仅划分为 2 类，分类结果过于粗略，难以体现我国人口区域分布在核心城市、传统人口大省、边疆民族地区、快速增长地区之间的差异。

因此，综合轮廓系数和实际解释性，本文选择： $K=4$ ，即将 31 个省级区域划分为 4 类。该分类数虽然轮廓系数不是最高，但更符合题目“人口区域分布类别划分”的实际分析需求。

3. 聚类中心结果分析

聚类中心结果如下。

聚类编号	人口规模均值	2000—2020 增长率	2010—2020 增长率	老龄化加深幅度	综合得分
1	17.7174	0.0108	较高	0.0438	0.2984
2	17.7063	0.0018	较低	0.0792	0.2199
3	16.7919	0.0208	较高	0.0535	0.3663
4	15.6551	0.0138	较高	0.0347	0.5523

从聚类中心可以看出：

第一，第 4 类综合得分最高，为 0.5523，但人口规模均值最低。这说明该类地区不是依靠人口总量取胜，而是在人口增长潜力、年龄结构和老龄化压力方面表现较好。

第二，第 3 类综合得分为 0.3663，主要对应北京、天津、上海。这类地区人口规模并非最大，但受教育水平、城镇化率和人口集聚能力明显较强。

第三，第 2 类综合得分最低，为 0.2199，且老龄化加深幅度最高，为 0.0792，说明这类地区人口增长动力偏弱，老龄化压力较突出。

第四，第 1 类处于中间状态，既包含部分沿海人口流入地区，也包含部分西南、西北地区，表现为增长潜力较强但内部差异较大。

4. 人口区域分布分类结果

根据 K-means 聚类结果，并结合各类地区人口结构特征，最终得到如下分类。

类别	地区数量	包含地区	类别特征
高城镇化高素质核心集聚型	3	北京、天津、上海	城镇化率高，平均受教育年限高，大专及以上学历人口占比高，人口集聚能力强
人口增长吸纳型	4	海南、西藏、青海、宁夏	人口规模较小，但人口增长潜力较强，老龄化压力相对较轻
传统大人口综合型	24	河北、山西、内蒙古、辽宁、吉林、黑龙江、江苏、浙江、安徽、福建、江西、山东、河南、湖北、湖南、广东、广西、重庆、四川、贵州、云南、陕西、甘肃、新疆	人口规模较大或中等，结构差异明显，既有传统人口大省，也有部分增长型和老龄化压力较大的地区

需要注意的是，虽然模型设定为 4 类，但最终自动命名时，第 1 类和第 2 类均被归并为“传统大人口综合型”，因此最终输出表中呈现为 3 个命名类别。这说明当前命名规则偏粗，若论文中需要严格呈现 4 类，建议将“传统大人口综合型”进一步拆分为：

聚类编号	建议类别名称
1	年轻化增长吸纳型
2	传统大人口老龄化承压型
3	高城镇化高素质核心集聚型
4	小规模潜力增长型

这样更符合最初设定的 4 类结构，也更利于后续问题 2、问题 3 和问题 4 展开分析。

5. 结果





图1 综合得分排序

基于人口结构特征的省级区域聚类结果



类型	包含地区	核心特征
第一类：年轻化增长吸纳型	广东、福建、江西、广西、贵州、云南、浙江、新疆	人口增长能力较强，少儿人口占比较高，老龄化压力相对较轻，部分地区具有较强人口流入能力

视频思路资料+可运行代码，请看【评论区置顶】免费获取！9

第二类：传统大人口老龄化承压型	河北、山西、内蒙古、辽宁、吉林、黑龙江、江苏、安徽、山东、河南、湖北、湖南、重庆、四川、陕西、甘肃	人口规模较大，但增长速度偏低，老龄化加深幅度较高，人口结构压力明显
第三类：高城镇化高素质核心集聚型	北京、天津、上海	城镇化率和受教育水平显著较高，人口集聚特征明显
第四类：小规模潜力增长型	海南、西藏、青海、宁夏	人口规模较小，但综合得分最高，人口增长潜力较强，老龄化压力相对较轻

6. 分类结果解释

6.1 高城镇化高素质核心集聚型

北京、天津、上海被划入该类。该类地区平均受教育年限为 11.9133 年，平均城镇化率为 0.8490，明显高于其他类别。

这说明该类地区的人口分布特征主要表现为：

人口高度向城市集中；

人口受教育水平高；

公共服务和产业资源集中；

对外来人口具有较强吸引力。

因此，该类地区并不是传统意义上的“大人口区域”，而是典型的高质量人口集聚区域。

6.2 传统大人口老龄化承压型

该类地区包括河北、山东、河南、四川、江苏、湖北、湖南、辽宁、吉林、黑龙江等地区。

该类地区的突出特点是：

人口规模较大；

人口增长速度较低；

老龄化加深幅度较高；

部分地区存在人口流出压力。

尤其是东北地区，虽然人口基础较大，但近年来人口增长动力不足，老龄化压力较明显。河南、山东、四川等省份虽然仍是人口大省，但人口增长优势正在减弱。

因此，该类地区可概括为：

人口基数大，但结构压力逐渐增强。

6.3 年轻化增长吸纳型

该类地区包括广东、福建、浙江、江西、广西、贵州、云南、新疆等。

该类地区整体表现为：

人口增长率相对较高；

少儿人口占比较高；

老龄化程度相对较低；

部分地区具有较强人口流入能力。

其中，广东、浙江、福建属于经济吸纳型增长地区，人口增长更多来自产业集聚和外来人口流入；贵州、云南、广西、新疆则更多体现为年龄结构较年轻和自然增长潜力较强。

因此，该类地区可以理解为：

人口增长动能较强、年龄结构相对年轻的潜力型区域。

6.4 小规模潜力增长型

海南、西藏、青海、宁夏被划入该类。

该类地区综合得分最高，为 0.5523，但人口规模较小。这说明该类地区虽然人口总量不大，但在人口增长率、老龄化压力和年龄结构方面具有相对优势。

其中，海南受自由贸易港建设、旅游服务业发展和人口迁入影响，近年来人口吸引力增强；西藏、青海、宁夏则表现出较强的年轻化特征和较低老龄化压力。

因此，该类地区可概括为：

人口规模小，但未来增长潜力较明显。

我国人口区域分布已经不再单纯表现为“人口多与少”的差异，而是表现为人口增长能力、人口素质、年龄结构和城镇化水平共同作用下的多类型分化格局。

5.2 问题二模型建立与求解

5.2.1 问题二求解思路

5.2.2 问题二模型建立

5.2.3 问题二模型求解与分析

5.3 问题三模型建立与求解

5.3.1 问题三求解思路

5.3.2 问题三模型建立

5.3.3 问题三模型求解与分析

视频思路资料+可运行代码，请看【评论区置顶】免费获取！11

六、模型分析检验

6.1 灵敏度分析

6.2 误差分析

七、模型评价与推广

7.1 模型的优点

- (1) 模型充分结合实际, 简化 xx, xx, xx 条件, 考虑了诸多重要因素得到合理的模型, 如:xx, xx, xx。这样得到的模型贴合实际, 具有较高的应用价值, 可以推广到 xx; 【模型的假设好】
- (2) 模型运用 xx 和 xx 思想, 抓住影响 xx 问题的重要因素, 将复杂的 xx 问题转化为简单的 xx 问题, 合理设置参数, 模型的输出结果符合题目要求, 能解决实际问题; 【模型的参数好】
- (3) 本文使用的 xx 算法具有 xx, xx, xx 等优点, 对于求解 xx 模型非常适用; 【模型的求解算法好】
- (4) 本文得到的 xx(安排方案、策略)具有效率高、输出稳定、xx 均衡等特点, 基本不存在 xx, xx, xx 等问题, 在现有条件下能有效提高生产效率。【模型的结果好】

7.2 模型的不足

- (5) 实际应用中, xx 和 xx 可能也是重要的因素, 但本文未能考虑到这些因素的影响, 一定程度上影响了模型的准确性; 【模型不够好】
- (6) 本文提出的模型对于现有条件使用效果较好, 由于时间问题没有对其他情况进行检验。对于其他情形(如:xx, xx), 可能无法达到较好的效果; 【模型适用范围较窄】
- (7) 实际上 xx, xx 的影响不一定是线性的, 而本文将其作为线性因子处理, 忽略了边际效应的影响。【模型的因素有些不好】

7.3 模型的推广

【推广: 在 xx 方面, 可以将 xx 参数替换成 xx 参数, 从而解决 xx 问题;
改进: 结合参考文献 xx, 进一步考虑 xx 的影响, 从而得到更合理的模型;
这部分不用太多, 至少 4 行】

参考文献

引用别人的成果或其他公开的资料(包括网上查到的资料)必须按照规定的参考文献的表述方式在正文引用处和参考文献中均明确列出。正文引用处用方括号标示参考文献的编号,如[1][3]等;引用书籍还必须指出页码。参考文献按正文中的引用次序列出,其中

书籍的表述方式为:

[编号] 作者, 书名, 出版地: 出版社, 出版年.

参考文献中期刊杂志论文的表述方式为:

[编号] 作者, 论文名, 杂志名, 卷期号: 起止页码, 出版年.

参考文献中网上资源的表述方式为:

[编号] 作者, 资源标题, 网址, 访问时间(年月日).

- [1] 汤国生.基于 SWOT 分析法的大学生数学建模创新实践基地建设探索——以江苏科技大学为例[J].高教学刊,2023,9(11):53-56.DOI:10.19980/j.CN23-1593/G4.2023.11.013.
- [2] 谢雨婧,韩惠丽.北师大版初中数学教材中数学建模的多维度分析[J].教学与管理,2023(09):73-76.
- [3] 刘志梅.数学建模与高职数学教学的深度融合[J].佳木斯职业学院学报,2023,39(03):152-154.
- [4] 许亚桃,吴立宝.基于 Delphi-AHP 高中数学建模教学评价指标体系的研究[J].内江师范学院学报,2023,38(02):113-119.DOI:10.13603/j.cnki.51-1621/z.2023.02.018.
- [5] 杨本朝,石雅男,段乾恒,李光松,于刚.大学生数学建模竞赛开展全周期教学实践探究[J].大学教育,2023(04):44-46.
- [6] 黄健,徐斌艳.国际视野下数学建模教与学研究的发展趋势——基于第 14 届国际数学教育大会的分析[J].数学教育学报,2023,32(01):93-98.

附录

附录 1
第 1 问求解代码
第 2 问求解代码
第 3 问求解代码
第 4 问求解代码